

HGNN (HiGeNagaNeko) RAGナレッジベース

AIで作ると、さもすごうそうな...

LLAMA.CPP, NLDOCR-Lite, Sudachi他に感謝

AIでごによごによ作ったので、いろいろとあると思う...

NDLOCR-LiteによるPDFのOCR処理で文書をデータベース化してRAG検索をしています。

RAG検索はSudachiを使用してインデックス化しています。

DBとインデックスはSQLite, FTS5, BM25で構成しています。

LLMはllama.cppを使用しているので、一般的なGGUFが使えると思います。

AI対話検索（Chat）の利用にはLLMモデルのダウンロードが必要です。

download_model.batで"LFM2.5-1.2B-JP-GGUF"をダウンロード

モデルによっては回答がいまいちだったり文字化けだったりエンドレスになったり...

※上記を指示して作ったつもりで、そうならないかも...

アプリケーション概要

4つのコンポーネントで構成される統合ドキュメント管理基盤



Ingestor

NDLOCR-Liteによる
OCR処理と
データベース構築



Search

キーワードによる
高速全文検索



Chat (RAG)

AIと対話しながら
知識ベースを検索・要約
※ LLMの事前ダウンロードが
必要



Editor

PDFページの
並べ替え・削除・結合

推奨フォルダ構成

大分類 / 中分類 / 小分類（ファイル名）の2階層構成を推奨

kb/

└─ 01_プロジェクトA/

│ └─ 01_仕様書/

│ │ └─ 要件定義書.pdf

│ └─ 02_議事録/

│ └─ 2026-05-04_会議.pdf

└─ 02_製品マニュアル/

└─ 01_取扱説明書/

└─ ユーザーガイド.pdf



ベースフォルダ

kb（ナレッジベース）



大分類

プロジェクト・製品単位



中分類

ドキュメント種類別



小分類

個別PDFファイル



Ingestor

`hgnn_ingest.py`

PDFや画像ファイルを読み込み、
NDLOCR-LiteでOCR処理を行い検索可能な
データベースを構築します。

主要機能



PDF / 画像対応

PDF、PNG、JPGなどのファイル形式をサポート



データベース構築

NDLOCR-LiteのOCR結果を構造化して保存し、高速なインデックスを自動構築



メンテナンス機能

既存データの修正、再OCRで上書きしてデータ更新

主要機能



高速全文検索

NDLOCR-Liteで取得したOCRテキストをキーワードで瞬時に検索



PDFページプレビュー

検索結果から該当ページを即座にプレビュー表示



テキスト修正

NDLOCR-LiteのOCR結果を検索画面から修正



Search

[hgnn-search.py](#)

構築されたデータベースに対して
キーワードによる高速な
全文検索を行います。

RAG-Chat (AI対話)

`hgnn-ragchat.py`

AIと対話しながら知識ベースの内容を要約します。

関連ドキュメントを検索し、検索結果に基づいた回答を生成します。

※ 利用前にLLMモデル（GGUF形式）の事前ダウンロードが必要です





Editor — PDF編集ツール

hgnn-editor.py | PDFのページ構成を自在に編集



ページ並べ替え

サムネイルをドラッグ&ドロップで直感的にページ順を変更



ページ削除

不要なページを選択して一括削除



ページ回転

スキャン時の向き間違いを回転で修正



PDF結合

複数のPDFファイルを1つのファイルに統合

使い方ワークフロー

1

データ取り込み

run_ingest.bat を実行し、
フォルダを選択してNDLOCR-LiteでOCR処理を開始

2

検索と閲覧

run_search.py を実行し、
キーワード入力で該当ページを表示

3

AIとの対話

run_ragchat.bat を実行し、
質問を入力してAIが関連資料をもとに回答
※ LLMモデルの事前ダウンロードが必要

4

PDFの整理

run_editor.bat を実行し、
PDFのページ並べ替え・結合・保存

動作要件 & 主要ラブラリー

動作要件

- Python 3.12
- Windows
- run_ingest.bat, run_ragchat.bat ...
- pip install -r requirements.txt

主要ライブラリ

NDLOCR-Lite

日本語OCR

llama-cpp-python

ローカルLLM推論

SudachiPy

日本語形態素解析



完全ローカル動作

llama-cpp-python によるローカルLLM推論を採用。

機密文書も外部送信なしに安全に処理できます。

※ Chat (RAG) 機能の利用にはGGUF形式のLLMモデルを事前にダウンロードしてください